

# Projet Data Pipeline

1-Contexte

2-Présentation & architecture de la Data Pipeline

3-Modèle utilisé

4-Résultats du modèle

5-Analyse Critique

6-Démonstration

7-Rôles


# 1-Contexte

But : Trouver et prédire la longueur des sépales en fonction de leur largeur

Comment : En utilisant une pipeline de données dockerisée de A à Z

Grâce à quoi : Un modèle de prédiction régressif (random forest) et une pipeline en Python et Dockerfile

# 2-Présentation & architecture de la Data Pipeline



# 3-Modèle utilisé

## **Algorithme utilisé : Random Forest Regressor**

Notre modèle utilise un **Random Forest**, un algorithme d'apprentissage automatique particulièrement adapté à la prédiction de valeurs numériques.

## **Comment ça fonctionne ?**

Le Random Forest crée une "forêt" composée de **200 arbres de décision** indépendants. Chaque arbre analyse les caractéristiques de la fleur (largeur du sépale) pour estimer la longueur du sépale. La prédiction finale est la **moyenne des prédictions** de tous les arbres, ce qui rend le modèle plus fiable et robuste.

## **Données d'entraînement**

Le modèle a été entraîné sur le **dataset Iris** contenant 150 échantillons de fleurs avec leurs mesures réelles. Les données ont été prétraitées (normalisation, suppression des doublons) pour optimiser la qualité des prédictions.

# 4-Résultats du modèle

Performances			Configuration du modèle		
Métrique	Valeur	Interprétation	Métrique	Valeur	Signification
R <sup>2</sup> (Note de l'algorithme)	-0.61	⚠ Modèle limité (voir ci-dessous)	Modèle	Random Forest + Polynomial Feature	Extraction des données + ensemble d'arbres
RMSE (Mesure de l'erreur)	1.05 cm	Erreur moyenne de ±1 cm	Arbres	200	Erreur moyenne de ±1 cm
MAE (Erreur moyenne réelle)	0.73 cm	En moyenne, on se trompe de 0.7 cm	Degré polynomial	3	Crée x, x <sup>2</sup> , x <sup>3</sup> à partir de sepal_width

# 5-Analyse Critique

## Forces

$R^2 = -0.6088$  : Explique -60% de la variance

RMSE = 1.04 cm : Erreur enorme

Random Forest : Robuste au sur-apprentissage

Temps de prédiction < 1ms : Réponses instantanées

200 arbres : Décisions + fiables que 100 arbres

API RESTful & Dockerisation : Intégration facile dans n'importe quel système

## Faiblesses

Dataset limité : Seulement 149 échantillons

Données normalisées : L'utilisateur doit fournir des valeurs normalisées

Pas de mise à jour dynamique : Modèle figé après entraînement

sepal\_width n'est pas un bon prédicteur de sepal\_length.  
C'est une contrainte du sujet, pas un bug du code.

Pas de gestion des outliers : Prédictions potentiellement erronées sur valeurs extrêmes

Pas de persistance des prédictions : Historique non sauvegardé

# 6-Démonstration

Testez moi ici !

# 7-Rôles

Rôle	Nom
API	Sacha
Modèle	Adrien
Data Preparation	Kamel
Front	Josh
Présentation	Kamel/Adrien